

Universidade Cesumar - Unicesumar



Trabalho de IA

Classificação de Spam com KNN e SVM

Integrantes: Antonio Ferreira de lima - 23038173-2
Gabrielle Morente Perna - 23217729-2
Karen Tanaka - 23026540-2
Leonardo Leitão Souza- 23020085-2

Engenharia de Software | 7º Semestre | Turma A | Noturno

Maringá, 16 de outubro de 2026

Contextualização

Este trabalho tem como foco a aplicação prática de dois algoritmos clássicos de aprendizado de máquina — KNN (K-Nearest Neighbors) e SVM (Support Vector Machine) — para a tarefa de classificação de mensagens SMS como spam ou ham (não-spam).

A escolha dos modelos se deu pois para o tipo de dataset que queríamos, o KNN estudado no 1º bimestre e o SVM Hiperplano estudado no 2º se encaixaram melhor pois ambos funcionam bem com classificação binária — que é exatamente o nosso caso, onde cada mensagem precisa ser classificada em uma de duas categorias. O KNN foi escolhido pela sua simplicidade: ele basicamente olha para as mensagens mais parecidas com a que chegou e decide com base nelas, o que faz bastante sentido para texto. O SVM entrou como segundo modelo porque queríamos comparar essa abordagem mais simples com algo mais robusto — o SVM aprende a traçar uma fronteira entre spam e ham no espaço vetorial e é reconhecido por funcionar muito bem com dados de texto em alta dimensionalidade. A ideia foi colocar os dois para rodar com os mesmos dados e ver na prática qual performa melhor.

E para que os modelos conseguissem trabalhar com texto, as mensagens foram convertidas em vetores numéricos utilizando a técnica TF-IDF (Term Frequency-Inverse Document Frequency), que atribui pesos às palavras com base em sua frequência na mensagem e em sua raridade no conjunto de dados. Palavras muito comuns em todo o dataset recebem peso menor, enquanto palavras mais específicas e relevantes recebem peso maior. Foram considerados unigramas e bigramas (sequências de uma ou duas palavras), com no máximo 5.000 features.

Problema

O problema abordado neste trabalho é a classificação binária de mensagens SMS, com o objetivo de determinar automaticamente se uma mensagem é spam ou ham (não-spam).

A classificação manual desse tipo de conteúdo é inviável em larga escala, tornando necessária uma solução automatizada capaz de aprender a partir de exemplos rotulados.

Hipótese

Nossa hipótese é que mensagens de spam possuem características linguísticas distintas das mensagens legítimas, como o uso frequente de palavras ligadas a prêmios, urgência, dinheiro e links, além de apresentarem maior comprimento e maior proporção de letras maiúsculas. Com base nessas diferenças, acreditamos que modelos de aprendizado de máquina treinados com representações TF-IDF serão capazes de classificar corretamente a grande maioria das mensagens. Além disso, esperamos que o SVM supere o KNN nessa tarefa, por ser um modelo mais adequado para espaços de alta dimensionalidade como os gerados pela vetorização de texto.

Descrição do Dataset

Foi utilizado o SMS Spam Collection Dataset, disponibilizado publicamente pelo UCI Machine Learning Repository e também disponível no Kaggle.

Exemplo de dado do dataset:

Coluna	Tipo	Descrição	Exemplo
label	Texto	Classe da mensagem: ham (legítima) ou spam	spam
message	Texto	Conteúdo completo da mensagem SMS	"Congratulations! You've won a FREE prize..."

Como obter o dataset:

1. Acesse: <https://www.kaggle.com/datasets/uciml/sms-spam-collection-dataset>
2. Faça download do arquivo 'spam.csv';
OU
3. Acesse o documento intitulado spam.csv.

Métodos de IA utilizados

KNN (K-Nearest Neighbors)

O KNN é um algoritmo de aprendizado supervisionado baseado em similaridade. Para classificar uma nova mensagem, ele encontra as k mensagens mais próximas no espaço vetorial e atribui a classe mais comum entre elas.

Configuração utilizada:

- k = 5 vizinhos Métrica de distância: cosseno (mais adequada para vetores TF-IDF esparsos) Processamento paralelo com n_jobs=-1
- O KNN é um modelo simples e interpretável, porém pode ter desempenho limitado em espaços de alta dimensionalidade, como os gerados pela vetorização de texto.

SVM (Support Vector Machine)

O SVM é um algoritmo de aprendizado supervisionado que busca encontrar o hiperplano de máxima margem que separa as classes no espaço vetorial. A variante utilizada foi o LinearSVC, que é otimizada para problemas de classificação de texto com alta dimensionalidade.

Configuração utilizada:

- Kernel linear (LinearSVC) Parâmetro de regularização: C = 1.0 Máximo de iterações: 2.000
- O SVM é especialmente eficiente para problemas de texto, pois funciona bem em espaços com muitas dimensões e pequena quantidade relativa de amostras.

Pipeline utilizado

Ambos os modelos foram encapsulados em um Pipeline do scikit-learn, garantindo que a vetorização TF-IDF e a classificação ocorram de forma integrada e sem vazamento de dados entre treino e teste. TF-IDF Vectorizer → [KNN ou SVM].

Avaliação dos Modelos de IA

Modelo	Acurácia	Precisão	Revocação	F1-Score
KNN	0.9704	0.9531	0.8188	0.8809
SVM	0.9830	0.9851	0.8859	0.9329




Figura 1 - Gráfico de Análise Exploratória do Dataset

Comparação dos Resultados

Matriz de Confusão




Figura 2 - Matrizes de Confusão

Comparação de desempenho




Figura 3 - Comparação de Desempenho - KNN vs SVM

Conclusão

Este trabalho tem como foco a aplicação prática de dois algoritmos clássicos de aprendizado de máquina — KNN (K-Nearest Neighbors) e SVM (Support Vector Machine) — para a tarefa de classificação de mensagens SMS como spam ou ham (não-spam).

Depois de treinar e comparar os dois modelos, ficou claro que o SVM se saiu melhor que o KNN para esse tipo de problema. Isso já era esperado — o SVM é um algoritmo feito para trabalhar bem em espaços com muitas dimensões, que é exatamente o que acontece quando a gente transforma texto em vetores TF-IDF com 5.000 features.